

# project

December 2, 2025

## 1 Progetto FESI - Baldini Filippo *S6393212*

Tentativo di rimuovere **rumori e distorsioni** da tracce audio (*mono*) registrate tramite un giradischi soggetto a diversi tipi di interferenze (*Rega P1 - IO*)

---

In questo caso possiamo parlare di ***Rumore Addittivo***, il segnale dunque corrispondera a:

$$X(m) = S(m) + N(m)$$

Dove: -  $X(m)$  rappresenta il Segnale Rumoroso. -  $S(m)$  rappresenta il Segnale Pulito. -  $N(m)$  rappresenta il rumore addittivo.

```
[168]: # Import
import numpy as np
import matplotlib.pyplot as plt
import scipy.io.wavfile as wav
import IPython
import warnings

import librosa as lb # Libreria per sound-processing
import soundfile as sf # Libreria per esportare .wav

[169]: # Costanti
FS = 48000 # frequenza di campionamento dei file del dataSet
NOISE_SECTION = 5 # Ultimi secondi del brano = rumore puro (per dominio)
N_FFT = 2048 # Dimensione della finestra della STFT
HL = 512 # Overlap-Add, dopo aver analizzato i primi 2048 campioni non passo ai
↳2048 successivi
      # ma ai 2048/4 successivi (512), necessario per non creare artefatti
↳(sovrapposizione)

track_wav="../../dataSet/input/arpeggi_1.wav"
noise_wav="../../dataSet/noise.wav"

OUTPUT_WIENER="../../dataSet/output/outputW.wav"
OUTPUT_SOTTSPETTR="../../dataSet/output/outputSS.wav"
OUTPUT_SOGLIATURA="../../dataSet/output/outputS.wav"
```

```
OUTPUT_NORM_SS = "../dataSet/output/outputN_SS.wav"
OUTPUT_NORM_W = "../dataSet/output/outputN_W.wav"
OUTPUT_WAVELET = "../dataSet/output/output_WV.wav"
```

### 1.0.1 Partiamo analizzando il *fenomeno rumoroso*

Otteniamo questo dato registrando l'output dell'amplificatore senza alcun brano in riproduzione (*rumore puro*)


### 1.0.2 FFT

```
[170]: # Analizziamo il rumore
nfs, noise = wav.read(noise_wav) # creo l'array

N = len(noise) # Lunghezza dell'array noise (dei campioni)

# Proviamo a calcolare la trasformata di Fourier con la funzione np.fft.fft di
# numpy
nf = nfs/N * np.arange(N) # asse delle frequenze
FFT_noise = np.fft.fft(noise)/N # DFT dell'intero array
noise_freq = np.fft.fftfreq(N, 1/nfs) # Vettore delle frequenze

plt.subplot(2,1,2)
plt.plot(noise_freq,np.abs(FFT_noise),'-r',label="$X_f(f)$")
plt.xlabel('f [Hz]')
plt.tight_layout()
plt.grid()
```



L'approccio con una *singola Trasformata di Fourier (FFT)* sull'intero brano è inadatto, perché tratta il segnale come *statico*. Così facendo, si ottiene uno spettro che ha un'altissima risoluzione in frequenza, ma perdiamo completamente i riferimenti temporali. Si perde tutta l'informazione su quando una frequenza appare.

Dato che la musica è un segnale *non-stazionario* (che evolve continuamente), dobbiamo passare a una *Short-Time Fourier Transform* (**STFT**). Analizzando il segnale a fette così mantenendo il legame frequenza-tempo.

La dimensione della finestra della **STFT**, **N\_FFT** e' il parametro che definisce quanti campioni consideriamo per ogni trasformata. se tale finestra fosse molto ampia avremo una alta risoluzione in termini di frequenze campionate ma una pessima risoluzione temporale, vice versa per una finestra piu' corta.


### 1.0.3 STFT

```
[171]: noise, sr = lb.load(noise_wav, sr=FS) # come per wav.read, ma crea un array di
      ↪ Float piuttosto che di Interi con Frequenza di Campionamento pari a FS =
      ↪ 48000Hz
      STFT_noise = lb.stft(noise, n_fft = N_FFT, hop_length=HL) # eseguo la
      ↪ trasformata di Fourier (STFT) con le finestre prescelte

      noise_mod = np.abs(STFT_noise) # considero il modulo della trasformata ossia
      ↪ una matrice bidimensionale (spettrogramma frequenza-tempo)
      noise_profile = np.mean(noise_mod, axis=1) # esegue la media lungo l'asse 1
      ↪ (tempo), quindi creando un vettore di intensita' (ampiezze)
      f = lb.fft_frequencies(sr=sr, n_fft=N_FFT) # asse delle frequenze da mettere a
      ↪ confronto con il profilo (lo definisco una sola volta)


      noise_db = lb.amplitude_to_db(noise_profile, ref=np.max) # converte i float
      ↪ delle frequenze dell'array noise in decibel

      plt.plot(f, noise_db, '-r', label="$Noise$")
      plt.xlabel('f [Hz]')
      plt.ylabel('Ampiezza (dB)')
      plt.legend()
      plt.tight_layout()
      plt.grid()
```



```
[172]: # Spettrogramma del Rumore:
noise_mod_db = lb.amplitude_to_db(noise_mod, ref=np.max)
lb.display.specshow(noise_mod_db, sr=sr, hop_length=HL, x_axis='time',
    ↪y_axis='log')

plt.colorbar(format='%+2.0f dB')
plt.title('Spettrogramma del Rumore')
plt.xlabel('Tempo (s)')
plt.ylabel('Frequenza (Hz)')
plt.tight_layout()
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```



#### 1.0.4 Ora procediamo con l'analisi del *brano* (rumoroso)

```
[173]: # Riproduciamo il brano di partenza contenente il rumore
IPython.display.Audio(track_wav)
```


```
[173]: <IPython.lib.display.Audio object>
```

```
[174]: # Analizziamo il Brano
track, sr = lb.load(track_wav, sr=FS) # Questo comando carica il segnale e
↳ restituisce : segnale (array float), frequenza_campionamento
STFT_track = lb.stft(track, n_fft = N_FFT, hop_length=HL) # eseguo la
↳ trasformata di Fourier (STFT) con le finestre prescelte

track_mod = np.abs(STFT_track) # considero il modulo della trasformata (freq,
↳ time)
track_profile = np.mean(track_mod, axis=1) # esegue la media lungo l'asse 1
↳ (tempo), quindi creando un vettore di intensita' (ampiezze)

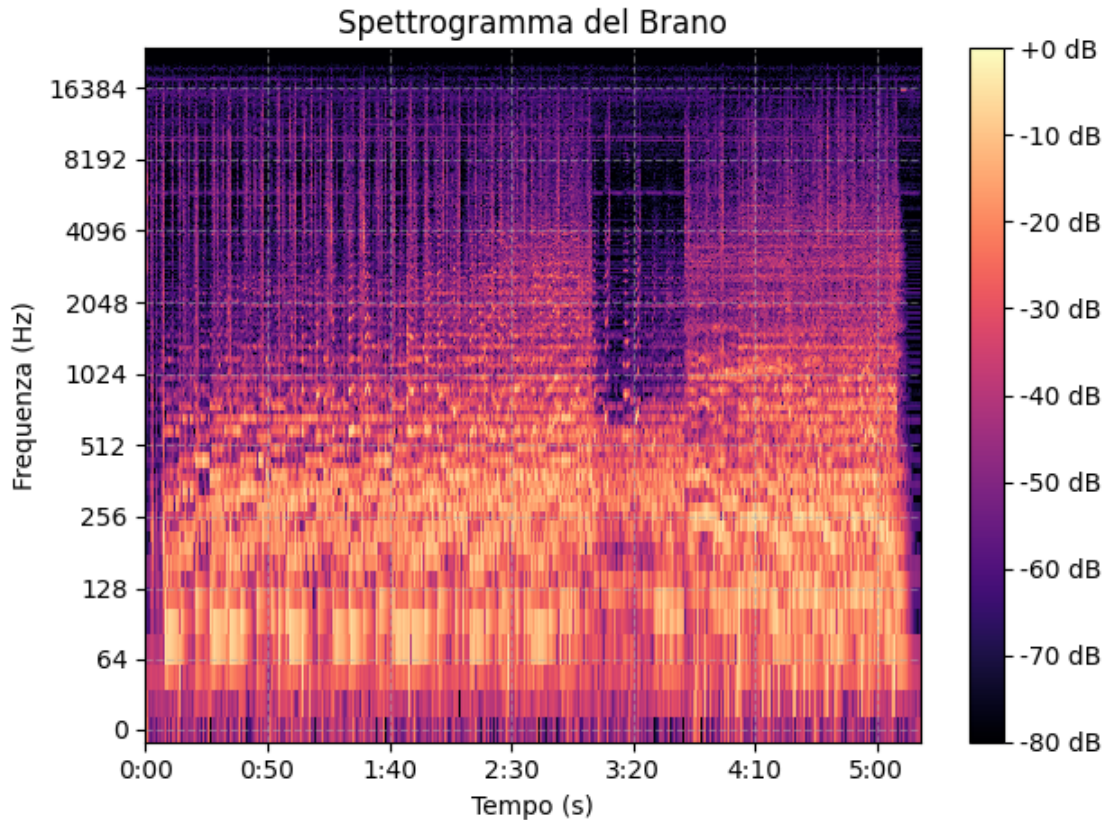
track_db = lb.amplitude_to_db(track_profile, ref=np.max) # converte i float
↳ delle frequenze dell'array noise in decibel
```

```
[175]: plt.plot(f, track_db, '-r', label="$X_f(f)$")
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')
plt.legend()
plt.tight_layout()
plt.grid()
```



```
[176]: # Spettrogramma del Brano:
track_mod_db = lb.amplitude_to_db(track_mod, ref=np.max) # considero la
↳ trasformazione in decibel della matrice 2D che definisce lo spettrogramma
lb.display.specshow(track_mod_db, sr=sr, hop_length=HL, x_axis='time',
↳ y_axis='log')

plt.colorbar(format='%+2.0f dB')
plt.title('Spettrogramma del Brano')
plt.xlabel('Tempo (s)')
plt.ylabel('Frequenza (Hz)')
plt.tight_layout()
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```



### 1.0.5 Denoising

Possiamo scegliere fra due Approcci, o utilizziamo il rumore in se come riferimento, rischiando di avere registrazioni effettuate in condizioni diverse oppure, per assicurarci che **Rumore** e **Brano** siano stati registrati con gli stessi *parametri*, aggiungiamo la condizione che i file in input *terminino con dei secondi di rumore puro* cosi' saremo in grado di estrapolare tale sezione assicurandoci cosi' di avere la stessa base di partenza (determinata dall'amplificatore (*volume*))

```
[177]: # Estraiamo il rumore dagli ultimi NOISE_SECTION secondi del brano
noise_samples = int(NOISE_SECTION * sr) # numero di campioni (secondi *
↪ frequenza)

# Dividiamo il brano in due: Musica e Rumore Finale
noise_part = track[-noise_samples:]
music_part = track[:-noise_samples]
```

```
[178]: # Eseguiamo STFT del brano e del Rumore
STFT_track = lb.stft(music_part, n_fft=N_FFT, hop_length=HL)
STFT_noise = lb.stft(noise_part, n_fft = N_FFT, hop_length=HL)
```

```

track_mod = np.abs(STFT_track) # calcoliamo il modulo del brano (matrice 2D
    ↳ tempo-frequenza)
noise_mod = np.abs(STFT_noise) # idem per rumore

track_profile = np.mean(track_mod, axis=1) # esegue la media lungo l'asse 1
    ↳ (tempo), quindi creando un vettore di intensita' (ampiezze)
noise_profile = np.percentile(noise_mod, 75, axis=1) # considero i valori
    ↳ superiori all'x% dei casi, piu' aggressiva rispetto ad una media matematica

ref_value = max(np.max(track_profile), np.max(noise_profile)) # valore per
    ↳ normalizzare le due tracce

noise_db = lb.amplitude_to_db(noise_profile, ref=ref_value) # converte le
    ↳ ampiezze dell'array in decibel
track_db = lb.amplitude_to_db(track_profile, ref=ref_value) # idem per traccia

```

### 1.0.6 SNR, Signal to Noise Ratio

Metrica fondamentale per quantificare l'impatto che il rumore ha sul segnale in analisi, ha la forma (nel caso dei decibel dB):

$$SNR_{dB} = 10 \log_{10} \left( \frac{P_{Signal}}{P_{Noise}} \right)$$

Dove: -  $SNR_{dB}$  e' il rapporto Segnale-Rumore relativo ai decibel -  $P_{Signal}$  e' la potenza (modulo quadro) del segnale pulito -  $P_{Noise}$  e' la potenza del Rumore Addittivo

```

[179]: # Calcolo SNR del brano originale
noisePow = np.mean(noise_part ** 2)
noisySignalPow = np.mean(music_part** 2)

signalPow = np.maximum(noisySignalPow - noisePow, 1e-10)

snr = 10 * np.log10(signalPow / (noisePow + 1e-10))
print(f"-> SNR Originale: {snr:.2f} dB")

```

-> SNR Originale: 24.68 dB

```


[180]: plt.plot(f, track_db, '-g', label="$Track$")
plt.plot(f, noise_db, '-r', label="$Noise$")

plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')

plt.legend(loc="upper right")
plt.grid()

```





con questa vista possiamo notare un problema fondamentale, *il rumore vive nello stesso range di frequenze del brano* dunque l'applicazione di un semplice *filtro di soglia* rimuoverebbe gran parte dei dettagli del brano rendendolo irriconoscibile.

### 1.0.7 Sogliatura

```
[181]: # Esempio di Sogliatura
thresh_h = 20000
thresh_l = 10000


# find all the indices corresponding to frequencies greater than a threshold
idx = np.argwhere((np.abs(f) < thresh_h) & (np.abs(f) > thresh_l))
STFT_cut=np.copy(STFT_track)
STFT_cut[idx, :] = 0 # imposta l'ampiezza dei valori a zero

track_filt = np.mean(np.abs(STFT_cut), axis=1)
track_filt_db = lb.amplitude_to_db(track_filt, ref=np.max)

track_clean_filtered = lb.istft(STFT_cut, hop_length=HL) # Torniamo nel dominio
↳ del tempo
# Output
sf.write(OUTPUT_SOGLIATURA, track_clean_filtered, sr, subtype='PCM_24')
```

```
plt.plot(f, track_filt_db, '-r', label=f"Spettro Filtrato (- ({thresh_l} <_
↳{thresh_h}) Hz)")
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (db)')

plt.grid()
```



Evidentemente quindi non e' possibile eseguire una semplice sogliatura per rimuovere la parte rumorosa.

### 1.0.8 Sottrazione Spettrale

Procediamo con un primo tentativo di riduzione del Rumore tramite l'operazione di **Sottrazione Spettrale**, ossia tentiamo di *sottrarre* (operando su matrici 2D (*tempo-frequenza*)) una *stima dello spettro medio del rumore* (`profile_expanded`) dallo *spettro del segnale originale* (`track_mod`) (rumoroso).

$$|\hat{S}(m, f)| = \max(|X(m, f)| - |\hat{N}(m, f)|, 0)$$

Dove: -  $|\hat{S}(m, f)|$  rappresenta il modulo del segnale pulito stimato. -  $|X(m, f)|$  rappresenta il modulo del segnale rumoroso iniziale -  $|\hat{N}(m, f)|$  rappresenta il modulo dello spettro medio del

rumore.

Il metodo si basa sull'assunzione che il rumore sia una *componente addittiva e stazionaria* (o che vari molto lentamente) ovvero che il suo spettro medio non cambi significativamente tra i diversi *campioni* della **STFT**. Il profilo del rumore viene stimato analizzando i momenti di “silenzio” (in cui è presente solo il rumore puro), isolati precedentemente. È importante notare che, *matematicamente*, la sottrazione potrebbe generare valori negativi (ad esempio nelle zone di silenzio o dove *noise > segnale*). Poiché un'energia negativa non ha significato fisico, in tali casi il risultato viene forzato a zero (**clipping**)

Infine, per la ricostruzione del segnale nel dominio del tempo, la stima dello spettro di *magnitudine* pulita (**mod\_clean**) viene combinata con la **fase del segnale** rumoroso originale e trasformata tramite la *trasformata inversa di Fourier* (**ISTFT**)

### SPECTRAL SUBTRACTION - PDF

```
[182]: # Procediamo con un primo tentativo di riduzione del Rumore
profile_expanded = noise_profile[:, np.newaxis] # Passiamo da un vettore 1D
↳ (medie ampiezze rumorose) ad una versione 2D (con le dimensioni di track_mod)

# Sottrazione Spettrale: sottraiamo la stima del rumore e imponiamo valori non
↳ negativi
mod_clean = np.maximum(track_mod - profile_expanded, 0) # Dove era presente
↳ noise > track il rumore viene ridotto (0 indica il floor, x < 0 = 0)

track_phase = np.angle(STFT_track) # Otteniamo la fase (theta) del brano
STFT_clean = mod_clean * np.exp(1j * track_phase) # Eulero e~j

track_clean = lb.istft(STFT_clean, hop_length=HL) # Torniamo nel dominio del
↳ tempo con la trasformata inversa

# Output
sf.write(OUTPUT_SOTTSPETTR, track_clean, sr, subtype='PCM_24')
```


```
[183]: # Analisi spettrale del segnale pulito
clean_profile = np.mean(mod_clean, axis=1) # esegue la media lungo l'asse 1
↳ (tempo), quindi creando un vettore di intensita' (ampiezze)

f = lb.fft_frequencies(sr=sr, n_fft=N_FFT)
ref_value = max(np.max(track_profile), np.max(clean_profile)) # valore per
↳ normalizzare le due tracce

ss_db = lb.amplitude_to_db(clean_profile, ref=ref_value)

# Plot confronto
plt.figure()
plt.plot(f, track_db, '-g', label='Track originale')
plt.plot(f, ss_db, '-b', label='Track pulito')
```

```
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')
plt.title('Confronto Sottrazione Spettrale')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```



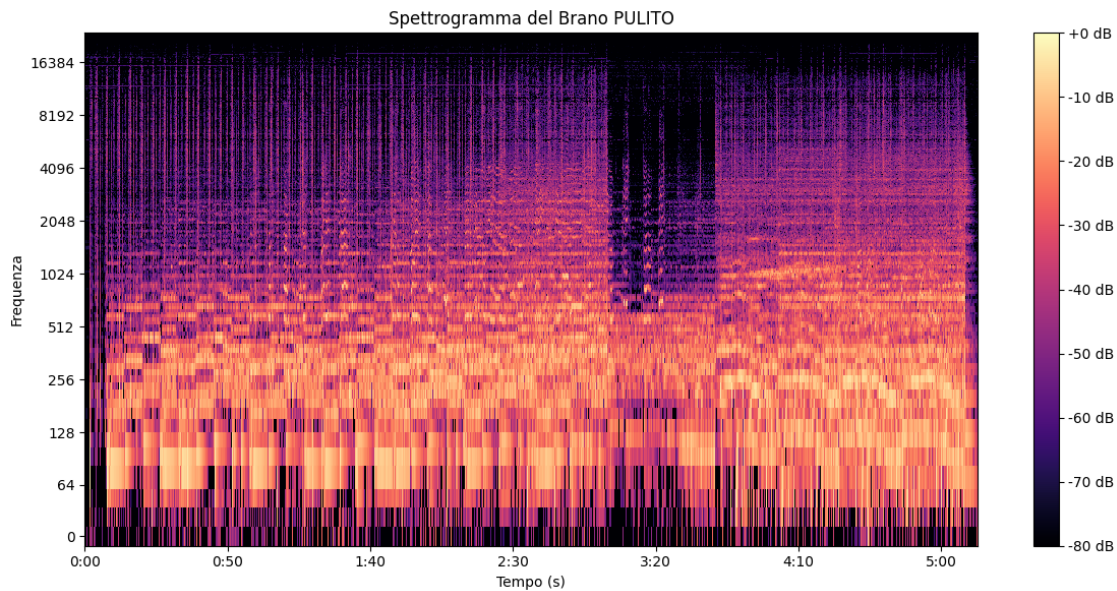
Notiamo come il segnale pulito pressocche' segua quello originale, con la piu' grande differenza osservabile fra i  $15000\text{Hz}$  -  $18500\text{Hz}$  dove risiedeva anche la gran parte del rumore udibile

```
[184]: clean_mod_db = lb.amplitude_to_db(mod_clean, ref=np.max)
plt.figure(figsize=(12, 6))

lb.display.specshow(clean_mod_db, sr=sr, hop_length=HL, x_axis='time',
                    y_axis='log')

plt.colorbar(format='%+2.0f dB')
plt.title('Spettrogramma del Brano PULITO')
plt.xlabel('Tempo (s)')
plt.ylabel('Frequenza')
```

```
plt.tight_layout()
plt.show()
```



```
[185]: # SNR - Sottrazione Spettrale
cleanPow = np.mean(mod_clean **2) # potenza del segnale pulito in seguito alla
↳Sottrazione Spettrale
modResidualNoise = np.maximum(noise_mod - profile_expanded, 0) # Applico la
↳sottrazione spettrale al rumore (sottraggo dalla matrice tempo-frequenza
↳della sezione rumorosa originale il vettore delle ampiezze espanso)
noisePow = np.mean(modResidualNoise **2)

signalPow = np.maximum(cleanPow - noisePow, 1e-10) # Stimo la potenza del
↳segnale puro

snr_ss = 10 * np.log10(signalPow / (noisePow + 1e-10))
print(f"-> Originale: {snr:.2f} dB")
print(f"-> SNR Sottrazione Spettrale: {snr_ss:.2f} dB")
print(f"    Sottrazione Spettrale vs Originale: +{snr_ss - snr:.2f} dB")
```

```
-> Originale: 24.68 dB
-> SNR Sottrazione Spettrale: 32.73 dB
    Sottrazione Spettrale vs Originale: +8.05 dB
```

### 1.0.9 Normalizzazione

Ascoltando il brano o analizzando il grafico ci rendiamo rapidamente conto che il volume originale risulta ribassato (banalmente si tratta di una sottrazione alla fine dei conti) dunque dobbiamo sottoporlo ad un processo di **normalizzazione**. Tale processo consiste nel trovare il sample massimo,

portarlo a  $\pm 1$  dB ed aggiustare gli altri campioni di conseguenza **Attenzione** Funziona solo se  $SNR_{dB} > 0$  (segnale originale), poich  se andassimo a considerare segnali con il rumore piu' potente che la traccia da preservare, `peak = np.max(np.abs(track_clean))` considererebbe come picco un valore rumoroso e dunque errato.

```
[186]: # Normalizzazione
peak = np.max(np.abs(track_clean)) # eseguo il valore assoluto del segnale
      ↪ pulito per trovare il valore massimo (nel dominio del tempo)
target_amp = 0.98


gain = target_amp/peak # calcolo il fattore di guadagno ossia di quanto devo
      ↪ incrementare la traccia (prodotto scalare)
track_norm = track_clean * gain

sf.write(OUTPUT_NORM_SS, track_norm, sr, subtype='PCM_24') # output
```

```
[187]: STFT_norm = lb.stft(track_norm, n_fft = N_FFT, hop_length=HL) # andiamo nel
      ↪ dominio delle frequenze
mod_norm = np.abs(STFT_norm) # calcoliamo il modulo (tempo-frequenza)
norm_profile = np.mean(mod_norm, axis=1) # esegue la media lungo l'asse 1
      ↪ (tempo), quindi creando un vettore di intensita' (ampiezze)

ref_value = max(np.max(norm_profile), np.max(track_profile), np.
      ↪ max(clean_profile)) # valore per normalizzare le due tracce
norm_db = lb.amplitude_to_db(norm_profile, ref=ref_value)

# Plot confronto
plt.figure()
plt.plot(f, norm_db, '-r', label='Track normalizzato')
plt.plot(f, ss_db, '-b', label='Track non normalizzato')
plt.plot(f, track_db, '-g', label='Track Originale')
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')
plt.title('Confronto Normalizzazione')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```



Ascoltando i risultati ottenuti e' evidente la presenza di **rumore residuo** e come descritto nel documento allegato (*III.A*), la sottrazione spettrale induce *musical noise* nel momento in cui troviamo sezioni anomale, con solo rumore, rumore stimato < rumore effettivo o vice versa. Tale *musical noise* e' quel rumore "acquoso" che rende suoni distorti e poco distinguibili dovuto all'applicazione di questo filtro.

[Combined Spectral Subtraction and Wiener Filter Methods in Wavelet Domain for Noise Reduction - PDF](#)

Dunque, seguendo il *paper* sopra citato, proviamo ad implementare un *filtro di Wiener*.

#### 1.0.10 Filtro di Wiener

Il *filtro di Wiener* e' una operazione che si basa su principi statistico-matematici, ha come obiettivo quello di trovare un filtro che renda la differenza (**errore quadratico medio**) tra il *segnale pulito ideale* e la nostra *stima* il più piccola possibile. In parole povere, cerca il compromesso matematicamente perfetto per salvare più musica possibile rimuovendo più rumore possibile.

Si basa su una assunzione fondamentale, che il *rumore* e il *segnale* siano **scorrelati**, ossia che sia un **fenomeno addittivo** (come nel nostro caso).

Matematicamente, il *guadagno del filtro*  $G(m, f)$  per ogni *frequenza*  $f$  e *istante temporale*  $m$  è definito dalla seguente formula:

$$G(m, f) = \frac{|\hat{S}(m, f)|^2}{|\hat{S}(m, f)|^2 + |\hat{N}(m, f)|^2} = \frac{|\hat{S}(m, f)|^2}{|X(m, f)|^2}$$

Dove: -  $|\hat{S}(m, f)|^2$  rappresenta la potenza (modulo al quadrato) del segnale pulito stimato. -  $|\hat{N}(m, f)|^2$  rappresenta la potenza dello spettro del rumore. - Il denominatore  $|\hat{S}(m, f)|^2 + |\hat{N}(m, f)|^2$  rappresenta l'energia totale del segnale rumoroso osservato ossia  $|X(m, f)|^2$

anche sottoponendo il segnale rumoroso a questo filtro, è possibile ottenere residui di **musical noise**. Tuttavia, rispetto alla **sottrazione spettrale**, questo fenomeno si presenta in **grado minore**, risultando talvolta sopprimibile o mascherabile con tecniche di smoothing temporale.

```
[188]: # Filtro di Wiener
N_AMP = 1 # Amplifica il rumore per essere piu' aggressivo
MIN_DB = 0.01 # Soglia minima

trackPow = track_mod **2 # Sarebbe il denominatore (Segnale Totale)
noisePow = (profile_expanded * N_AMP) **2 # Potenza del rumore stimato (dagli_
    ↪ultimi secondi del brano)

cleanPow = np.maximum(trackPow - noisePow, 0) # (S(m,f))

mask = cleanPow/(trackPow + 1e-10) # G(m,f), aggiungo un valore trascurabile_
    ↪per evitare situazioni scomode (0)
mask = np.maximum(mask, MIN_DB) # Se trovo porzioni di solo rumore (= 0) le_
    ↪imposto ad un minimo 1%

mod_clean = track_mod * mask # Applico il filtro (dominio delle frequenze,_
    ↪moltiplicazione)
STFT_clean = mod_clean * np.exp(1j * track_phase) # Eulero e~j

track_clean = lb.istft(STFT_clean, hop_length=HL) # Torniamo nel dominio del_
    ↪tempo con la trasformata inversa

# Output
sf.write(OUTPUT_WIENER, track_clean, sr, subtype='PCM_24')
```

La porzione di codice sopra presentata puo' esser riassunta nel seguente modo: 1) Calcolo il Filtro:  $\text{mask} = G(m, f)$  2) Applico tale filtro al modulo del segnale rumoroso originale `track_mod`:  $\text{mod\_clean} = |\hat{S}(m, f)| = |X(m, f)| \cdot G(m, f)$  3) Ricompongo il Segnale applicando al modulo pulito `mod_clean`,  $r$ , una fase  $\theta$  (del brano originale) `track_phase` mediante la formula di Eulero:  $z = r \cdot e^{j\theta}$  4) Eseguo la **ISTFT** e ottengo il segnale pulito

```
[189]: # Analisi del segnale pulito in seguito all'applicazione del filtro di Wiener
clean_profile = np.mean(mod_clean, axis=1) # esegue la media lungo l'asse 1_
    ↪(tempo), quindi creando un vettore di intensita' (ampiezze)

f = lb.fft_frequencies(sr=sr, n_fft=N_FFT)
```



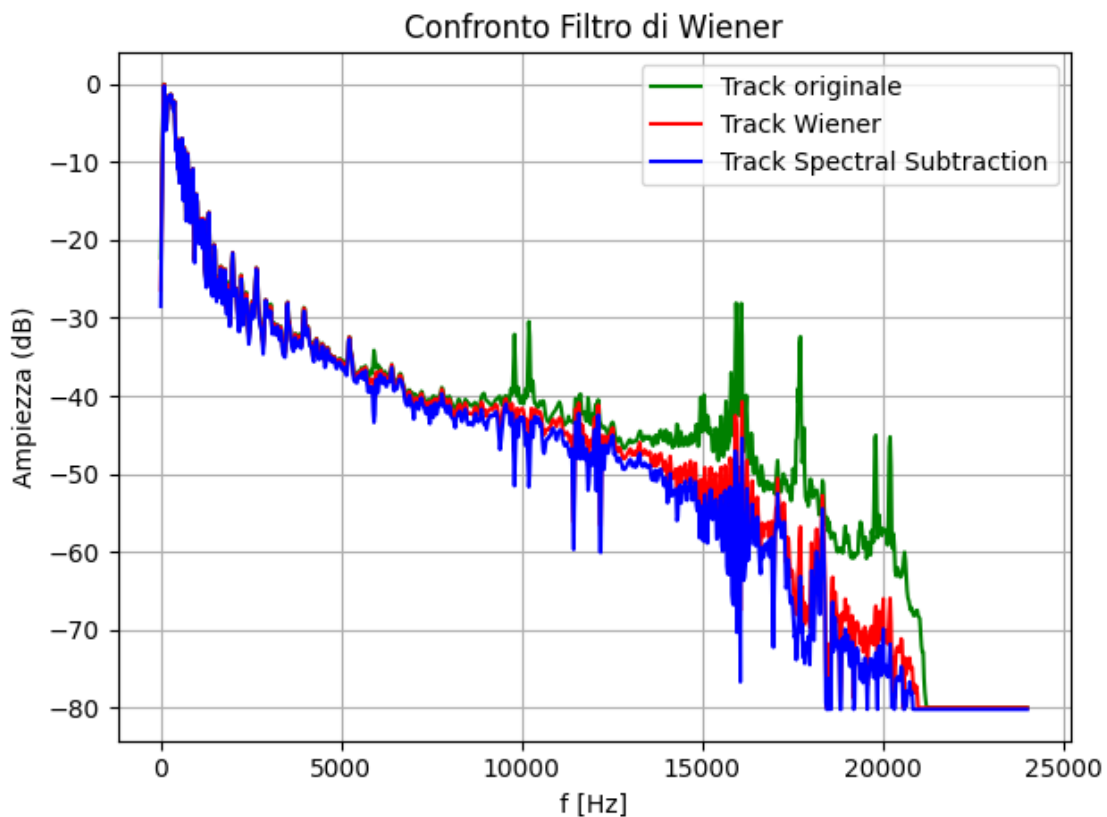
```

ref_value = max(np.max(track_profile), np.max(clean_profile)) # valore per
↳normalizzare le due tracce

w_db = lb.amplitude_to_db(clean_profile, ref=ref_value)

# Plot confronto
plt.figure()
plt.plot(f, track_db, '-g', label='Track originale')
plt.plot(f, w_db, '-r', label='Track Wiener')
plt.plot(f, ss_db, '-b', label='Track Spectral Subtraction')
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')
plt.title('Confronto Filtro di Wiener')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

```



Dal grafico si evince che abbiamo perso meno “*informazione musicale*” rispetto che ad una applicazione di un filtro piu’ severo.

Ad Esempio nella sezione piu' rumorosa sulle alte frequenze comprese fra  $15000\text{Hz}$  -  $18500\text{Hz}$ , il cambiamento fra il rapporto del **filtro di Wiener** e `np.maximum(track_mod - profile_expanded, 0)` della **Sottrazione Spettrale** e' evidente.


Il rumore di fondo, *musical\_noise* dovuto al taglio netto della **Sottrazione Spettrale** risulta eliminato all'udito (meno ovattato e alcune componenti risultano piu' distinguibili) tuttavia permane un rumore di sottofondo.

Note: Esplorando diversi valori di `N_AMP` e `MIN_DB` possiamo rendere piu' o meno aggressivo il filtro

```
[190]: clean_mod_db = lb.amplitude_to_db(mod_clean, ref=np.max)
plt.figure(figsize=(12, 6))

lb.display.specshow(clean_mod_db, sr=sr, hop_length=HL, x_axis='time',
    ↪y_axis='log')

plt.colorbar(format='%+2.0f dB')
plt.title('Spettrogramma del Brano PULITO')
plt.xlabel('Tempo (s)')
plt.ylabel('Frequenza')
plt.tight_layout()
plt.show()
```



```
[191]: # SNR - Filtro di Wiener
cleanPow = np.mean(mod_clean **2) # potenza del segnale pulito in seguito alla ↪
    ↪applicazione del filtro di Wiener

noisePow = noise_mod **2 # Sarebbe il denominatore (Segnale Totale)
```

```

profilePow = (profile_expanded * N_AMP) **2 # Potenza del rumore stimato
↳(dagli ultimi secondi del brano)

signalPow = np.maximum(noisePow - profilePow, 0) # Applico il filtro di wiener
↳al rumore

mask = signalPow/(noisePow + 1e-10) # G(m,f), aggiungo un valore trascurabile
↳per evitare situazioni scomode (0)
mask = np.maximum(mask, MIN_DB) # Se trovo porzioni di solo rumore (= 0) le
↳imposto ad un minimo 1%

modResidualNoise = noise_mod * mask

noisePow = np.mean(modResidualNoise ** 2)
signalPow = np.maximum(cleanPow - noisePow, 1e-10)

# Calcolo dB
snr_wf = 10 * np.log10(signalPow / (noisePow + 1e-10))
print(f"-> SNR Originale: {snr:.2f} dB")
print(f"-> SNR Sottrazione Spettrale: {snr_ss:.2f} dB")
print(f"-> SNR Filtro di Wiener: {snr_wf:.2f} dB")
print(f"    Filtro di Wiener vs Originale: +{snr_wf - snr:.2f} dB")
print(f"    Filtro di Wiener vs Sottrazione Spettrale: {snr_wf - snr_ss:.2f} dB")

```

```

-> SNR Originale: 24.68 dB
-> SNR Sottrazione Spettrale: 32.73 dB
-> SNR Filtro di Wiener: 29.98 dB
    Filtro di Wiener vs Originale: +5.30 dB
    Filtro di Wiener vs Sottrazione Spettrale: -2.75 dB

```

L'SNR del Filtro di Wiener risulta inferiore rispetto a quello della Sottrazione Spettrale poichè, come spiegato in precedenza, ha un taglio più delicato che aiuta a rimuovere le componenti rumorose ma limitando la creazione di artefatti indesiderati.

La Sottrazione Spettrale lascia un taglio molto più netto che corrisponde ad una maggior riduzione del rumore a costo però della chiarezza della traccia audio. Inoltre, a differenza del segnale filtrato tramite *sottrazione spettrale*, in questo caso possiamo **iterare** qualche volta il processo per ottenere un risultato sempre più pulito

```

[192]: # Normalizzazione
peak = np.max(np.abs(track_clean)) # eseguo il valore assoluto del segnale
↳pulito per trovare il valore massimo (nel dominio del tempo)
target_amp = 0.98

gain = target_amp/peak # calcolo il fattore di guadagno ossia di quanto devo
↳incrementare la traccia (prodotto scalare)
track_norm = track_clean * gain


```

```
sf.write(OUTPUT_NORM_W, track_norm, sr, subtype='PCM_24') # output
```

```
[193]: STFT_norm = lb.stft(track_norm, n_fft = N_FFT, hop_length=HL) # andiamo nel
↳ dominio delle frequenze
mod_norm = np.abs(STFT_norm) # calcoliamo il modulo (tempo-frequenza)
norm_profile = np.mean(mod_norm, axis=1) # esegue la media lungo l'asse 1
↳ (tempo), quindi creando un vettore di intensita' (ampiezze)

ref_value = max(np.max(norm_profile), np.max(track_profile), np.
↳ max(clean_profile)) # valore per normalizzare le due tracce
norm_db = lb.amplitude_to_db(norm_profile, ref=ref_value)

# Plot confronto
plt.figure()
plt.plot(f, norm_db, '-r', label='Track normalizzato')
plt.plot(f, w_db, '-b', label='Track non normalizzato')
plt.plot(f, track_db, '-g', label='Track Originale')
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')
plt.title('Confronto Normalizzazione')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```



La **STFT** porta con se una serie di *limitazioni*, in primis il compromesso legato al *dominio* stesso della trasformata.

La dimensione della finestra della **STFT**,  $N_{\text{FFT}}$  e' il parametro che definisce quanti campioni consideriamo per ogni trasformata. Se tale finestra fosse molto ampia avremo una alta risoluzione in termini di frequenze campionate ma una pessima risoluzione temporale, vice versa per una finestra piu' corta. Nel nostro caso questo significa o avere un'ottima riduzione del rumore con perdita della qualita' del brano o piuttosto, come presentato in questo notebook, sempre una alta fedelta' audio con un rumore limitato di sottofondo.

Esistono metodologie alternative per la scomposizione del segnale di partenza (permettendoci cosi' di analizzarlo), come presentato nel *paper* qui sotto citato, il dominio **Wavelet** promette di oltrepassare queste limitazioni e ottenere un segnale teoricamente piu' pulito.

In particolare, al contrario della **FFT**, non usa funzioni *trigonometriche* ma piuttosto funzioni omonime (*Wavelet*) che permettono la decomposizione e ricostruzione dei segnali, garantendo la possibilita' di analizzare cambiamenti delle frequenze nel tempo. Questa capacita' rende le trasformate **Wavelet** ideali per descrivere segnali non stazionari (suono). La Trasformata funziona applicando *iterativamente* filtri *passa alto* e *passa basso* per isolare ed eliminare le componenti rumorose e nel mentre preservare i dettagli piu' fini del segnale. Spesso utilizzato per le immagini puo' esser applicato anche per segnali 1D.

[Wavelet Domain - PDF](#)

Dopo una prima esplorazione del nuovo dominio provo ad applicare una semplice funzione di libreria di *skimage*, l'output risulta essere piu' rumoroso rispetto ai risultati ottenuti mediante manipolazioni con Fourier.

Probabilmente perche' tale funzione di libreria risulta fin troppo generica e non valuta correttamente un profilo del rumore.

```
[194]: import pywt
from skimage.restoration import denoise_wavelet


track = track / np.max(np.abs(track)) # Normalizzo la traccia
# Specifico il brano rumoroso, il metodo, che modalita' (soft, hard), quanto a
# fondo andare, che wavelet scegliere e un bool di rescaling
track_clean = denoise_wavelet(track, method='BayesShrink', mode='soft',
    wavelet_levels=6, wavelet='sym8', rescale_sigma=True)

# Plotting
STFT_wavelet = lb.stft(track_clean, n_fft=N_FFT, hop_length=HL)
mod_clean = np.abs(STFT_wavelet)
clean_profile = np.mean(mod_clean, axis=1)

f = lb.fft_frequencies(sr=sr, n_fft=N_FFT)
ref_value = max(np.max(track_profile), np.max(clean_profile)) # valore per
# normalizzare le due tracce
wl_db = lb.amplitude_to_db(clean_profile, ref=ref_value)

# Plot confronto
plt.figure(figsize=(12, 6))
plt.plot(f, track_db, '-g', label='Track originale')
plt.plot(f, wl_db, '-y', label="Track Wavelet")
plt.plot(f, w_db, '-r', label='Track Wiener')
plt.plot(f, ss_db, '-b', label='Track Spectral Subtraction')
plt.xlabel('f [Hz]')
plt.ylabel('Ampiezza (dB)')
plt.title('Confronto Filtro di Wiener')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

sf.write(OUTPUT_WAVELET, track_clean, sr, subtype='PCM_24') # output
```



Approfondendo lo studio in questa materia sono giunto alla conclusione che per il problema che devo affrontare, rumore per lo più stazionario e non impulsivo il dominio *wavelet* non è adatto perché tale dominio è intrinsecamente progettato per analizzare ed isolare *transienti* e *discontinuità localizzate nel tempo* (segnali non stazionari), sfruttando la sua capacità di *multirisoluzione*.

Al contrario, il rumore stazionario, qui considerato, è per definizione delocalizzato nel tempo (presente ovunque) e richiede un'alta risoluzione in frequenza per essere separato chirurgicamente.

La decomposizione **Wavelet** fatica a rappresentare questo tipo di rumore in modo '*sperso*' (ossia concentrandolo in pochi coefficienti), finendo per spalmarlo su molti coefficienti condivisi con la struttura armonica del brano; di conseguenza, il tentativo di rimuovere il rumore tramite sogliatura (*thresholding*) porta inevitabilmente a intaccare l'*integrità* del segnale musicale, causando perdita di brillantezza e un suono ovattato, rendendo l'approccio **STFT (Fourier)** nettamente superiore per questa specifica classe di problemi.